Praktikum 1

IF3170 Inteligensi Artifisial 2026/2027

Analisis Data Penayangan Film Layar Pertama Studio

Samuelson Dharmawan T

Nicholas Wise Saragih S

13524001 x 13524037

Latar Belakang & Tujuan

KONTEKS

Layar Pertama Studio ingin tahu **mengapa sebagian film disambut hangat penonton** sementara film lain tidak, dan apakah hal itu berkaitan dengan anggaran, genre, durasi, pemeran, atau sutradara.

4.803
film dalam arsip studio

MASALAH

Data tersimpan di **9 tabel terpisah** yang dicatat orang berbeda. Isinya masih memuat **nilai hilang, nilai 0 yang artinya "tidak diketahui"**, dan relasi satu-ke-banyak antar tabel.

9
tabel CSV saling berelasi

TUJUAN

Menyusun **satu tabel analisis yang bersih: 1 baris per film** dengan label kelas_rating (Low / Mid / High), lalu merangkum fitur dengan **PCA** agar model tetap ringan.

1
baris per film, siap dimodelkan

Gambaran Umum Dataset

Struktur Data

File	Isi	Baris × Kolom
film.csv	Tabel utama, 1 baris per film	**4.803 × 14**
genre.csv	Lookup nama genre	**20 × 2**
film_genre.csv	Relasi film ↔ genre (N:M)	**12.160 × 2**
kata_kunci.csv	Kata kunci tiap film	**36.194 × 3**
perusahaan_produksi.csv	Perusahaan produksi	**13.677 × 3**
negara_produksi.csv	Negara produksi	**6.436 × 2**
negara.csv	Lookup negara + benua	**184 × 3**
pemeran.csv	Pemeran + urutan kredit	**106.257 × 6**
kru.csv	Kru, departemen, jabatan	**129.581 × 6**

Semua tabel anak terhubung ke film melalui id_film

Alur Data Preparation (CRISP-DM)

TARGET (Y) **kelas_rating**

Tertile dari rataan_vote → **Low / Mid / High**. Film tanpa vote tidak diberi label.

Tantangan Utama

1. **Relasi 1-ke-N: 304.305 baris di 6 tabel anak**
2. **Nilai 0 dan kosong yang berarti "tidak diketahui"**

Exploratory Data **Analysis**

Kualitas & Distribusi Data Film

Missing Value & Nilai Nol

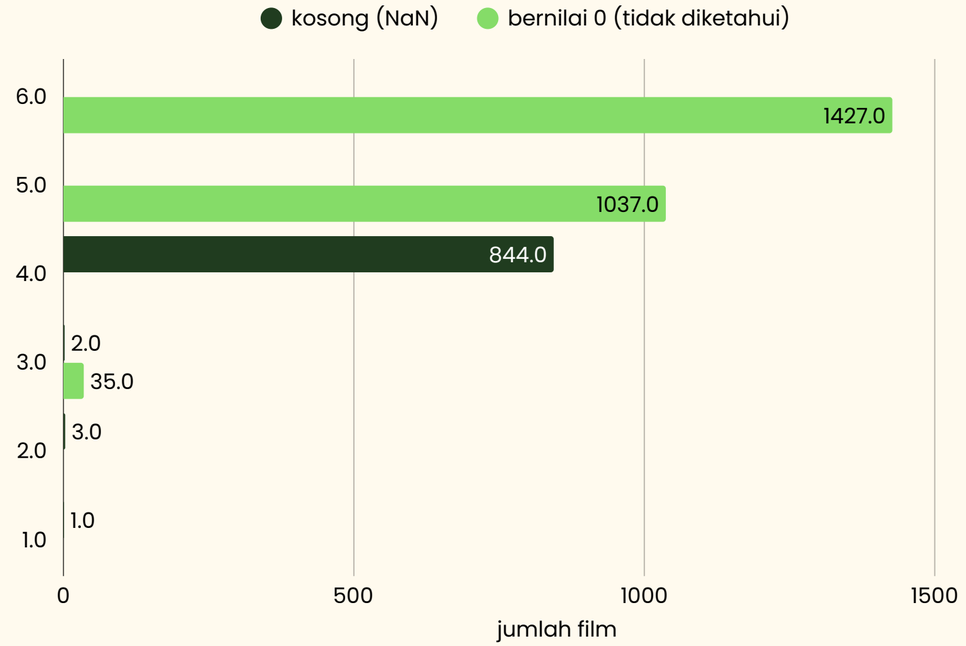

4.803 × 14
ukuran tabel film

3
judul ganda (dicek di Cleaning)

Distribusi Rating & Pendapatan

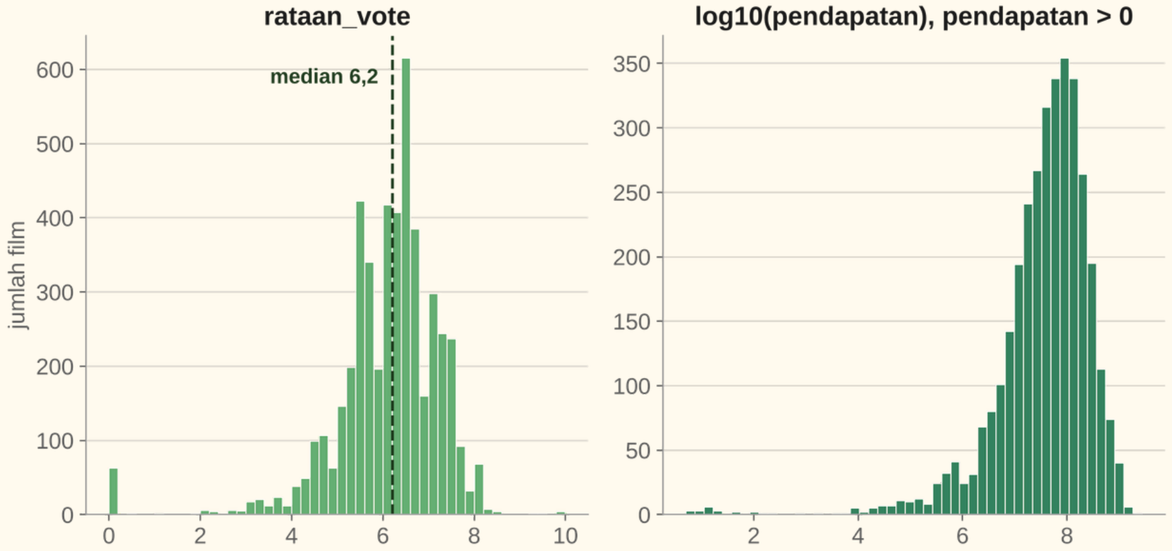

Nilai **0** pada anggaran, pendapatan, dan durasi berarti **tidak diketahui**, bukan benar-benar nol. **1.427 film (29,7%) berpendapatan 0**, dan pendapatan sangat condong ke kanan (maks ±2,79 miliar USD) sehingga perlu skala log.

Relasi Antar Tabel

Rata-rata Baris per Film

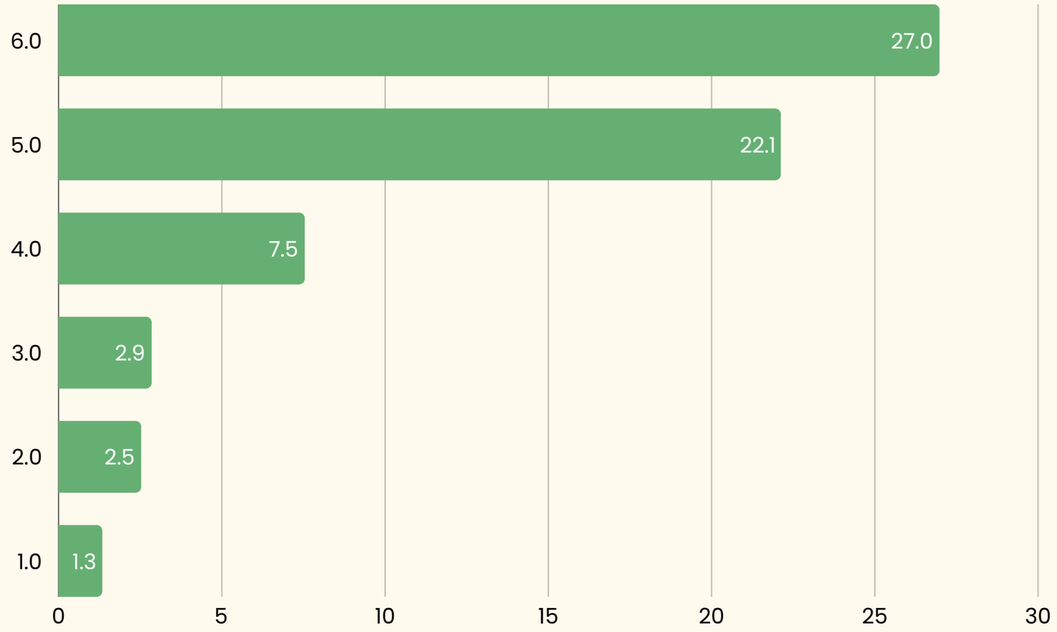

Satu film rata-rata punya **26,98 baris kru** dan **22,12 baris pemeran**

Relasi 1-ke-N ke film

Tabel anak	Baris	Film unik	Rata²/film
film_genre	12.160	4.775	**2,53**
kata_kunci	36.194	4.391	**7,54**
perusahaan_produksi	13.677	4.452	**2,85**
negara_produksi	6.436	4.629	**1,34**
pemeran	106.257	4.760	**22,12**
kru	129.581	4.775	**26,98**

Tidak semua film muncul di setiap tabel anak (mis. kata kunci hanya 4.391 film), jadi rasio ini rata-rata keseluruhan.

Tabel anak **wajib diagregasi** ke 1 baris per id_film sebelum di-join

Data Integration

Mengapa Tidak Langsung Merge?

Jika Tabel Anak Di-merge Langsung

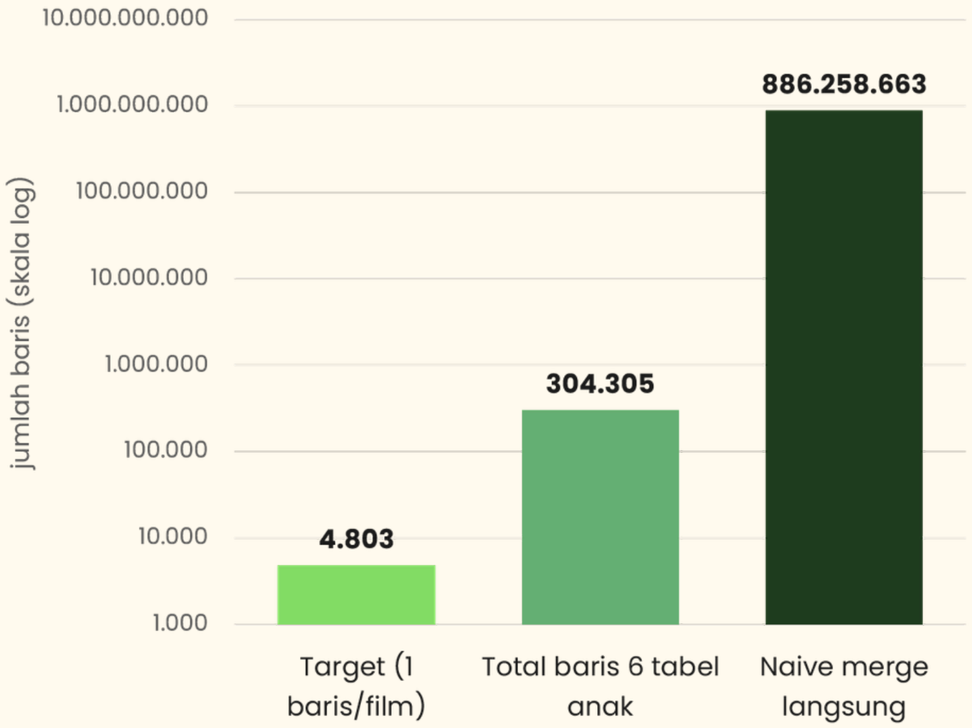

Setiap film berlipat sebanyak **hasil kali** jumlah barisnya di 6 tabel anak

Total baris tabel anak	Baris naive merge	Baris yang diinginkan
304.305	**886,26 jt**	**4.803**

Implikasi untuk Integrasi

- Agregasi tiap tabel anak dengan **groupby(id_film)**
- Join hasil agregasi ke **film** dengan **left join**
- Cek **validate='one_to_one'** agar tidak ada baris berlipat

Naive merge membuat ±184.500× lebih banyak baris daripada jumlah film, penuh baris duplikat.

Agregasi Tabel Anak ke Table Utama

film_genre + genre	kata_kunci	perusahaan_produksi	negara_produksi + negara	pemeran	kru
inner merge lookup	**size**	**size & first**	**left merge lookup**	**urut kredit · first**	**filter Director & nunique**
jumlah_genre genre_utama daftar_genre	jumlah_kata_kunci	jumlah_perusahaan perusahaan_utama	jumlah_negara negara_utama benua	jumlah_pemeran bintang_utama persen_pemeran_perempuan*	sutradara ukuran_kru jumlah_departemen

lakukan groupby('id_film') agar membuat 1 baris per film untuk tiap tabel anak

film.join(..., how='left')
semua 4.803 film tetap ada

validate='one_to_one'
menjamin tidak ada baris berlipat

kolom jumlah → fillna(0)
tidak punya baris = 0

master table: 4.803 baris × 28 kolom

* persen pemeran perempuan dihitung hanya dari kode jenis_kelamin 1 atau 2; kode 0 berarti tidak diketahui, bukan laki-laki.

Data Cleaning

Kebijakan Pembersihan Data

Semua keputusan sudah ditetapkan di awal sehingga hasil kode dapat dibandingkan langsung dengan Expected Output.

0 Nilai nol

`replace(0, NaN)`

anggaran, pendapatan, durasi bernilai 0 berarti tidak diketahui, jadi diubah menjadi NaN.

< Nilai tidak wajar

`< 1.000 USD → NaN`

Anggaran/pendapatan di bawah 1.000 USD tidak masuk akal. Total NaN: **1.069** anggaran, **1.449** pendapatan, **37** durasi.

× Tanggal rilis kosong

`dropna`

1 baris dibuang karena tahun & bulan rilis tidak dapat diturunkan (4.803 → 4.802).

≈ Imputasi

`median · modus · Unknown`

durasi → median, **genre_utama & benua** → modus, kolom **nama orang/perusahaan** → "Unknown".

= Duplikasi

`cek id & baris`

0 id_film ganda, **0** baris ganda. 3 pasang judul kembar ternyata film berbeda, jadi dipertahankan.

→| Outlier

`IQR clipping`

durasi & **popularitas** dipotong ke batas Q1 - 1,5 × IQR dan Q3 + 1,5 × IQR, bukan dihapus.

anggaran & **pendapatan** sengaja belum diimputasi: keduanya diisi di pipeline setelah **laba** dan **ROI** dihitung.

Missing Value & Duplikasi

Nilai Kosong: Sebelum vs Sesudah

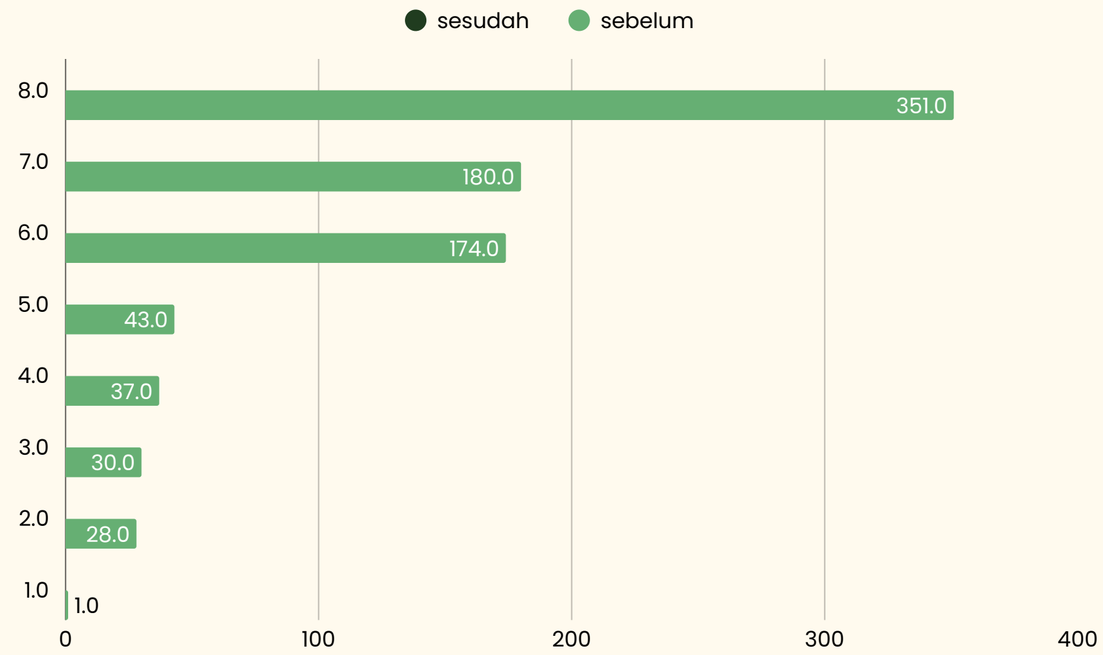

Kolom nama diisi **"Unknown"**, bukan modus, agar tidak mengarang identitas yang sama di banyak baris

Judul Kembar ≠ Duplikat

id_film	judul	rilis	sutradara
268	**Batman**	1989-06-23	Tim Burton
2661	**Batman**	1966-07-30	Leslie H. Martinson
39269	**Out of the Blue**	1980-05-01	Dennis Hopper
10844	**Out of the Blue**	2006-10-12	Robert Sarkies
72710	**The Host**	2013-03-22	Andrew Niccol
1255	**The Host**	2006-07-27	Bong Joon-ho

0
id_film ganda

0
baris ganda

4.802
baris setelah cleaning

Tahun rilis & sutradara berbeda → film berbeda, jadi **tidak dihapus**

Outlier: IQR Clipping

Sebelum Clipping

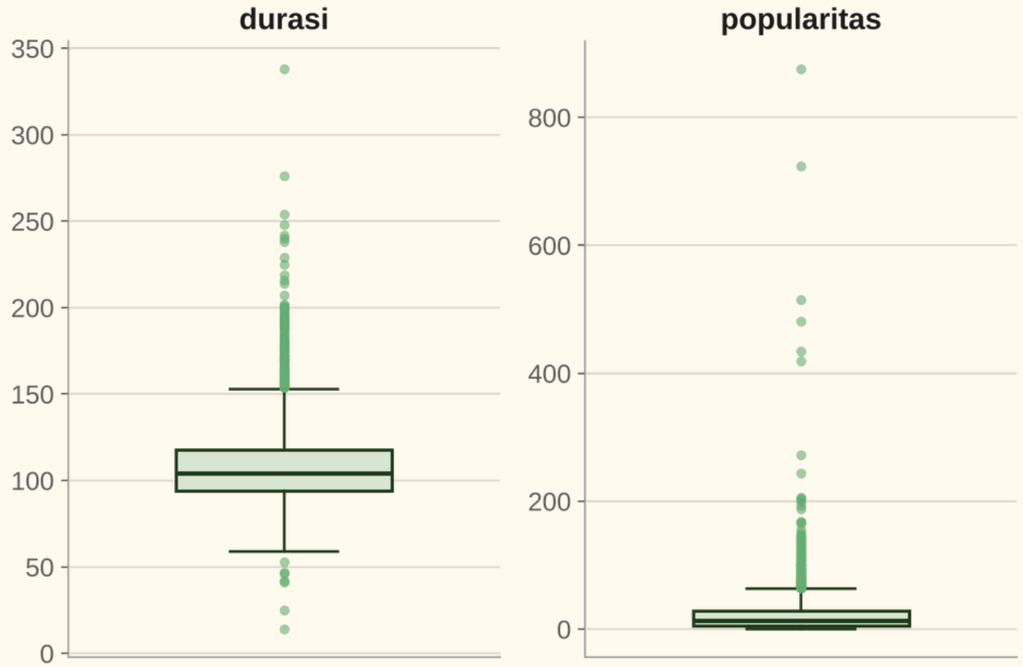

durasi

159 outlier

batas 58,38 – 153,38 menit

popularitas

275 outlier

batas -30,82 – 63,82

Sesudah Clipping

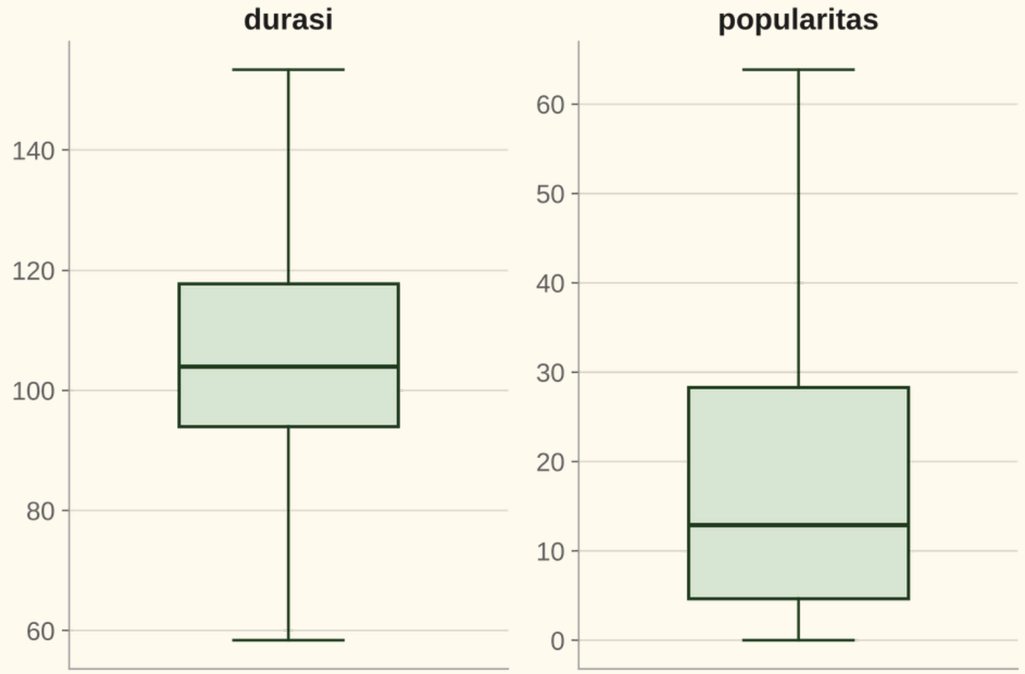

Nilai di luar **Q1 − 1,5·×IQR** dan **Q3 + 1,5×IQR** dipotong ke batas terdekat. Jumlah baris tetap **4.802**, tetapi nilai ekstrem berubah. Titik di luar whisker hanya **kandidat** outlier, bukan bukti nilai salah.

Data Transformation

Fitur Turunan, Diskretisasi & Log

Fitur Turunan

dari tanggal_rilis
tahun · bulan · kuartal_rilis (Q1–Q4)

dari finansial
laba = pendapatan - anggaran
roi = pendapatan / anggaran

Diskretisasi Durasi (batas 90 & 120 menit)

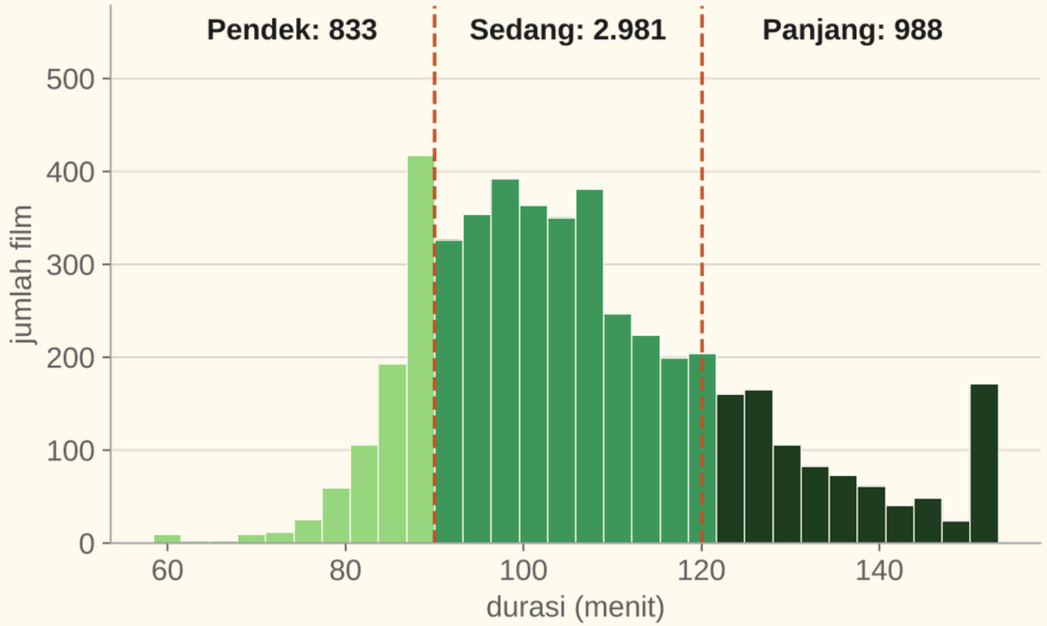

Transformasi log1p: Skewness

	sebelum		sesudah
anggaran	2,22	→	**-1,17**
pendapatan	3,88	→	**-1,20**
popularitas	1,11	→	**-0,45**
roi	49,73	→	**1,71**

Ekor kanan berkurang drastis (ROI 49,73 → 1,71). Hasil negatif pada anggaran & pendapatan menunjukkan log1p **tidak menjamin simetris**; bisa berbalik condong ke kiri.

laba & roi bernilai NaN bila anggaran atau pendapatan tidak diketahui.

Label kelas_rating & Pencegahan Leakage

Label kelas_rating (tertile)

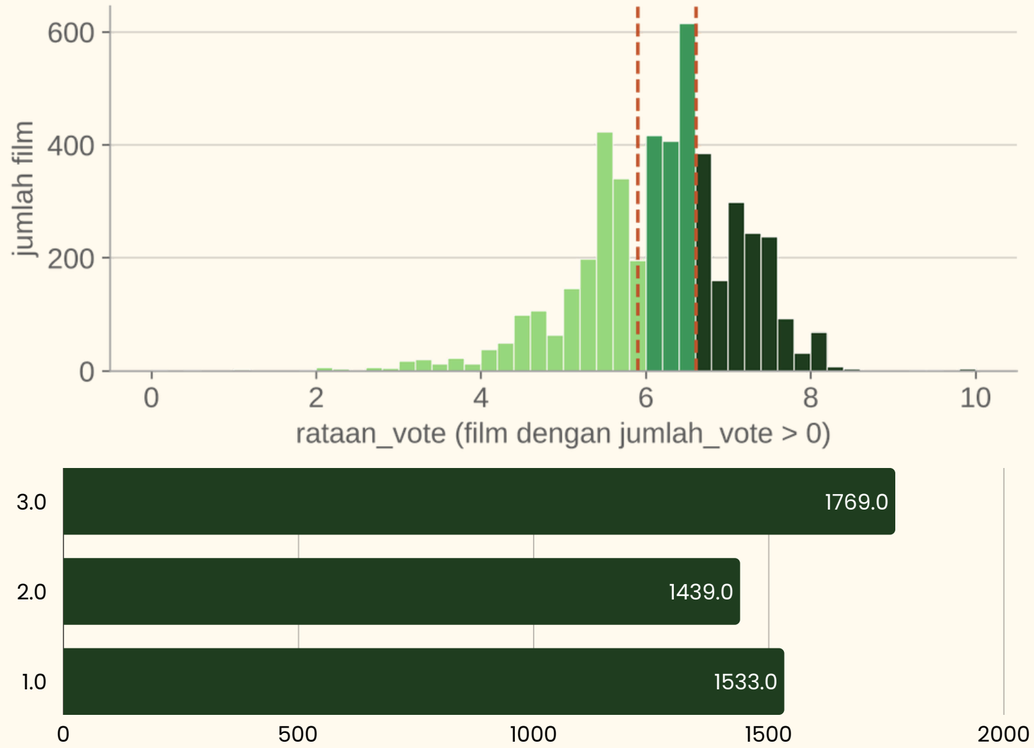

61 film tanpa vote dibuang → 4.741 film. Kelas tidak persis sama besar karena banyak nilai rating yang berulang di batas kuantil (5,9 dan 6,6).

Mencegah Kebocoran Label

Dibuang: bocor dari label

rataan_vote jumlah_vote label dibentuk langsung dari rating

Dibuang: teks & kardinalitas tinggi (11)

judul, judul_asli, tanggal_rilis, tagline, ringkasan, status, daftar_genre, perusahaan_utama, negara_utama, bintang_utama, sutradara

16	1	4
numerik	ordinal	nominal

Matriks fitur X: **4.741 × 21**

⚠ **Catatan kebocoran waktu**

Jika prediksi dilakukan sebelum rilis, **pendapatan** & **popularitas** baru diketahui setelah film tayang dan perlu ditinjau ulang.

Pipeline Scaling & Encoding

INPUT
21 fitur
16 numerik
1 ordinal
4 nominal

NUMERIK (16)
Imputer + Scaler
SimpleImputer (median) → StandardScaler

ORDINAL (1)
Ordinal Encoder
Pendek < Sedang < Panjang → 0, 1, 2

NOMINAL (4)
One-Hot Encoder
min_frequency=50 → kategori jarang digabung

OUTPUT
43 kolom
16 + 1 + 26 tanpa NaN

Kolom nominal	Kolom one-hot
bahasa_asli	3
genre_utama	14
benua	5
kuartal_rilis	4
Total	**26**

ColumnTransformer

Ketiga jalur dibungkus satu objek lalu fit_transform(X).
Hasil: matriks **4.741 × 43** dengan **0** nilai NaN.

Bila data dibagi train/test, pipeline di-fit hanya pada train agar statistik test tidak bocor.

Mengapa begini?

- **Median untuk imputasi**
  Tidak mudah tertarik nilai ekstrem; anggaran & pendapatan baru diisi di sini.
- **StandardScaler**
  Fitur berskala jutaan (anggaran) dan puluhan (durasi) jadi setara sebelum PCA.
- **Ordinal encoding**
  Urutan Pendek < Sedang < Panjang tetap terbawa ke angka.
- **min_frequency = 50**
  Kategori jarang digabung menjadi infrequent agar kolom tidak meledak.

Data Reduction

Seleksi Fitur Berbasis Korelasi

Matriks Korelasi 16 Fitur Numerik

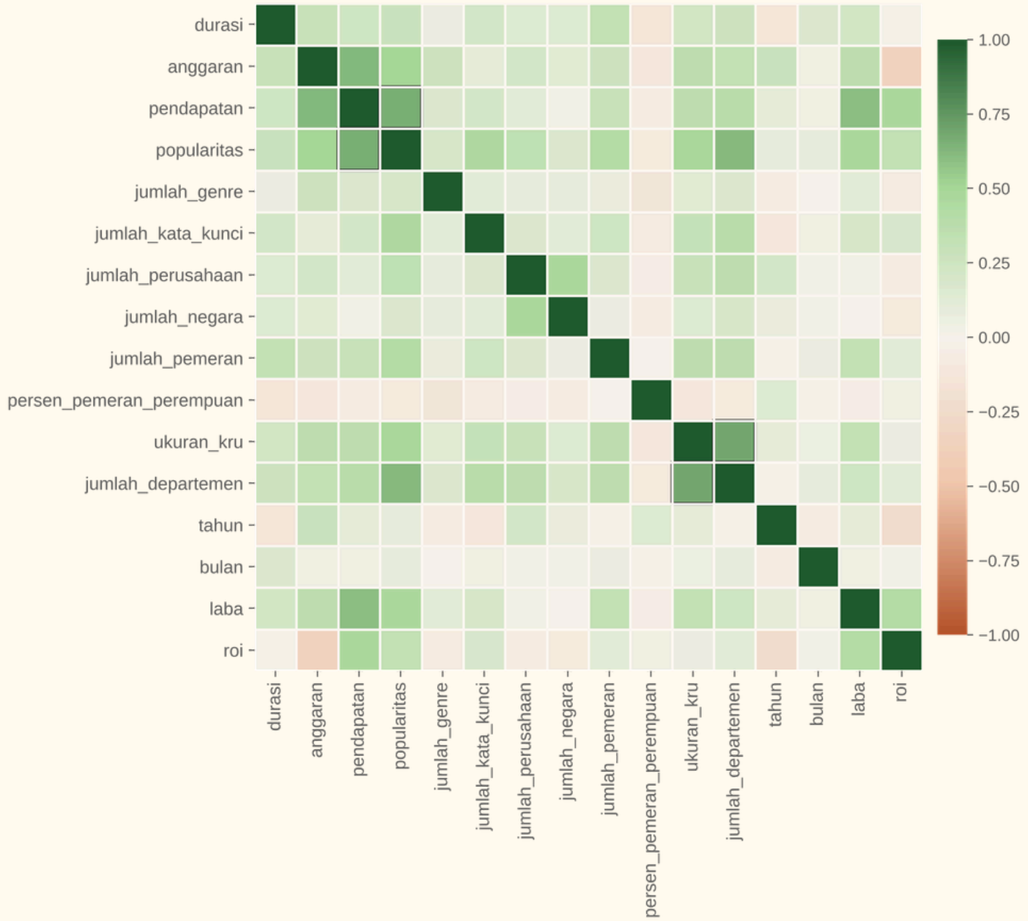

Pasangan |r| tertinggi

ambang 0,65

ukuran_kru ↔ jumlah_departemen dibuang: jumlah_departemen	**0,68**
pendapatan ↔ popularitas dibuang: popularitas	**0,66**
anggaran ↔ pendapatan	0,62
popularitas ↔ jumlah_departemen	0,61
pendapatan ↔ laba	0,60

Hanya segitiga atas matriks yang dicek, jadi setiap pasangan dihitung sekali. Ambang 0,65 lebih ketat dari kebiasaan (0,8–0,9).

16 → **14 fitur numerik**

Principal Component Analysis (PCA)

Varians Kumulatif

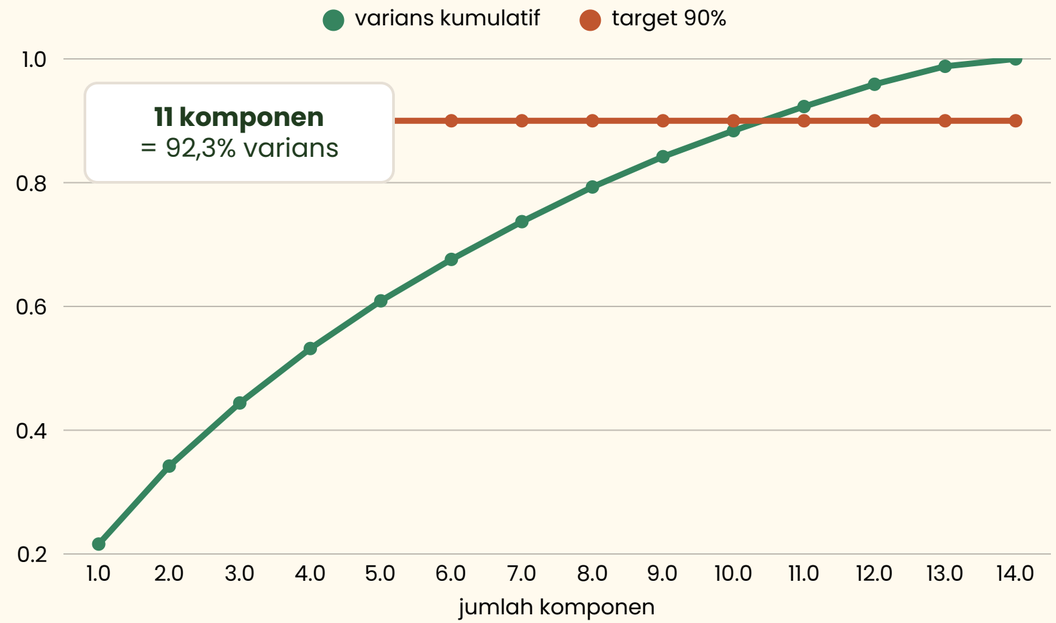

PC1 vs PC2 per kelas_rating

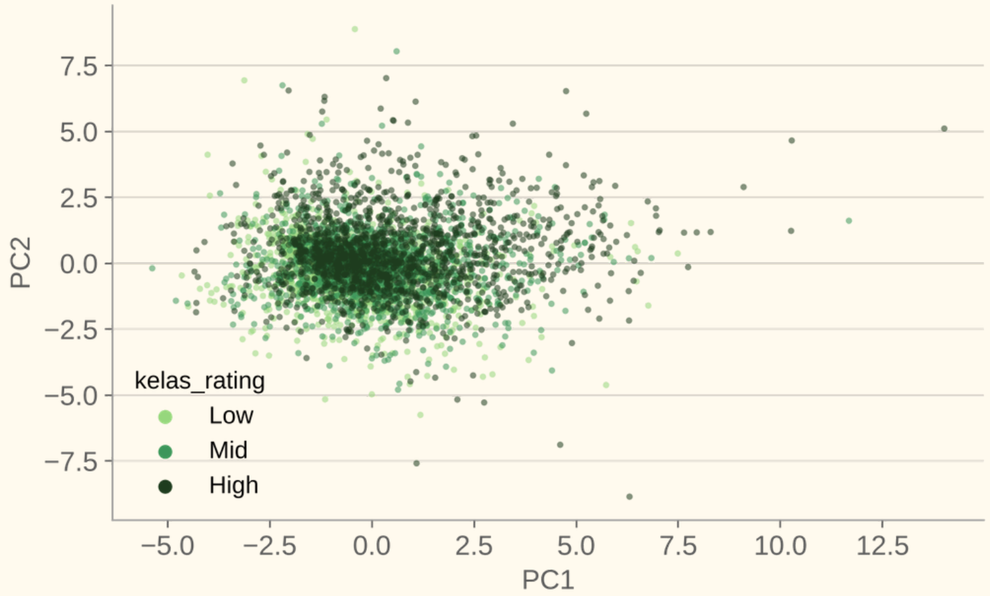

PC1 menjelaskan 21,6% varians

11 komponen → 92,3% varians

Loading PC1 terbesar: laba & pendapatan (0,40)

PCA tidak memakai label: PC1 mencerminkan **skala finansial**, dan ketiga kelas masih tumpang tindih pada dua komponen pertama.

Ringkasan

INTEGRATION

9 tabel menjadi **satu master table**. Tabel anak diagregasi per id_film lalu di-left join dengan validasi one-to-one, sehingga 886 juta baris naive merge tidak pernah terjadi.

4.803 × 28

film tetap utuh

CLEANING & TRANSFORMATION

Nol & nilai tidak wajar jadi NaN, imputasi median/modus/"Unknown", IQR clipping, fitur turunan, log1p, label tertile, lalu **scaling + encoding** dalam satu pipeline.

4.741 × 43

fitur siap model, 0 NaN

REDUCTION

Seleksi korelasi membuang **popularitas** & **jumlah_departemen**, lalu PCA merangkum 14 fitur numerik menjadi 11 komponen.

4.741 × 11

komponen PCA (92,3% varians)

Matur
Nuwun!